


Architecture et autoévaluation

[Retour au guide](#) · [Rapport technique existant](#)

Cette annexe explique les composants effectivement livrés et reprend, en les reformulant, les critères de la fiche d'autoévaluation liée à la mission. Les états indiquent les preuves observées ; aucun critère incomplet n'est présenté comme validé.

Schéma UML de composants simplifié



Les flèches pointent vers le composant appelé ou l’artefact produit. Les modules Python regroupent des fonctions : ce diagramme montre leurs responsabilités et dépendances, pas une hiérarchie de classes inexistante.

Le client appelle FastAPI. L'API délègue au service. Pour une question, le service utilise le moteur RAG et l'index local ; Mistral reste externe pour l'embedding de question et la réponse. Pour reconstruire, le service relit le Parquet et utilise l'indexation, qui appelle Mistral pour les vecteurs. La collecte est une étape préalable distincte.

Ce qui est vérifié, livré ou reste ouvert

Critère reformulé	État	Preuve et limite
Architecture et rôles des composants	Vérifié	Schéma UML de composants simplifié ci-dessus, modules métier séparés ; rapport et README explicitent les responsabilités.
Choix du modèle et adaptation métier	Livré, comparaison à compléter	Mistral imposé dans la mission ; mistral-embed pour la recherche ; Small historiquement et Ministral 8B pour la démo actuelle ; prompt Puls-Events. Pas de benchmark comparatif ni entraînement.
Descriptions transformées en vecteurs	Vérifié	14 903 vecteurs de 1 024 dimensions ; 7 586 UID représentés, modèle mistral-embed tracé dans le manifeste.
Chaîne LangChain et FAISS	Livré	Documents, splitters, retriever, prompt et clients Mistral ; l'orchestration est écrite dans le projet.
Pertinence des réponses annotées	Preuve initiale	4 cas locaux avec règles permissives ; 3 cas RAGAS, correction moyenne 0,683. Ce n'est pas une validation générale.
Tests des étapes du pipeline	Vérifié aujourd'hui	76 tests réussis ; services externes simulés dans la suite. Ingestion, chunks, index, RAG, API, démo et métriques couverts.
Tests relançables et résultats lisibles	Livré	python -m pytest -q ; scripts d'évaluation ; rapports JSON locaux. CI/CD proposée, pas implémentée.
Indicateurs et analyse des erreurs	Livré, à enrichir	Règles de titres, refus, exact match et similarité lexicale ; 4 métriques RAGAS. Petit jeu, détails fragiles et absence de seuil reconnu.

Critère reformulé	État	Preuve et limite
Dépôt lisible et reproductible	Livré	scripts/, src/, tests/, seed-data/, README, versions directes et Docker. Les supports de soutenance sont versionnés ; README constitue aussi un rapport.
Références humaines et comparaison automatisée	Livré	Deux CSV annotés ; evaluate_rag.py et evaluate_ragas.py. Le second est le vrai calcul RAGAS ; l'option --ragas du premier ne le remplace pas.
API /ask et /rebuild	Partiellement vérifié aujourd'hui	Serveur lancé, Swagger disponible ; deux scénarios /ask réussis avec Ministral 8B. /rebuild est livré mais non relancé pendant la préparation.
Validation et gestion des erreurs	Livré, durcissement à prévoir	Pydantic, rejet des questions vides, erreurs HTTP ; erreurs fournisseur contrôlées en 503/502 sans détails internes. La pagination concerne la collecte, pas la réponse top-k.
Lancement local	Vérifié	Image Docker existante démarrée via Compose. Aucun nouveau build complet affirmé ; dépendance Mistral distante.
Qualité et fraîcheur des données	À compléter pour aujourd'hui	Nettoyage et déduplication livrés. Seed de juillet 2026 : certains événements ont plus d'un an au 1er octobre ; horizon futur et actualisation à ajouter.
Contrat et exemples API	Vérifié	Swagger /docs, schéma OpenAPI, curl et scripts Python. GET /health existe ; /metadata cité comme exemple dans la fiche n'est pas livré ni nécessaire aux routes explicites du brief.
JSON exploitable et cas limites	Livré	question, answer, sources et retrieved_chunk_count ; refus Lyon enregistré. Pas de filtre de ville bloquant, ni seuil de pertinence.
Démo fluide et explication aux métiers	Direct vérifié aujourd'hui	Démonstrateur local avec direct et enregistrement explicitement séparés ; guide oral, exemples et glossaire. Le secours ne remplace pas l'exigence live.
Sécurité avant exposition publique	À compléter	Clé dans l'environnement, .env ignoré ; jeton /rebuild optionnel. Authentification globale, limite de débit et bascule atomique à prévoir ; erreurs fournisseur déjà filtrées.

Les points à garder en tête à 14 h

1. Le corpus figé doit être actualisé pour remplir durablement le besoin de sorties à venir et de données de moins d'un an.
2. La démo fonctionne avec Ministral 8B après une limite sur Small ; annoncer le changement et réévaluer la qualité.
3. Les résultats RAGAS sont historiques et portent sur trois cas ; la correction 0,683 montre une marge d'amélioration.
4. Les 76 tests valident les comportements du code avec des doublures, sans prouver la disponibilité du fournisseur.

Sources : code du dépôt, manifestes, corpus, sorties historiques et vérifications du 1er octobre ; fiche d'autoévaluation officielle liée au document de mission, consultée aujourd'hui.