

Un assistant culturel fondé sur des événements réels.

POC RAG · Puls-Events

7 586

événements à Paris

14 903

passages indexés

Hugo Gaube · Data scientist freelance

Projet 7 · 1er octobre 2026

Le RAG relie la réponse au catalogue

« Je cherche une sortie en famille à Paris avec une visite théâtralisée. »

01

Rechercher

Les passages proches
du sens de la question.

02

Augmenter

Donner ces passages
comme contexte à Mistral.

03

Répondre

Une recommandation
avec des sources.

Le RAG apporte des documents au modèle au moment de la question.

Le corpus est un instantané explicite de Paris

7 586

événements normalisés

10 juillet 2025



10 juillet 2026

Collecter

API publique Opendatasoft, données OpenAgenda.

Filtrer

Ville de Paris et première date dans la fenêtre.

Normaliser

Retirer le HTML, gérer les valeurs absentes, dédupliquer.

Conserver

Titre, description, lieu, dates, URL et catégories.

Corpus figé en juillet 2026 ; sa fraîcheur doit être réévaluée pour un usage actuel.

Les descriptions deviennent des passages recherchables

EXEMPLE RÉEL · CHIMERE

10 273

caractères dans la fiche

Passage 1 ... fin partagée

début partagé ... Passage 2

... 15 passages au total

1 000 / 200

caractères / chevauchement maximal

mistral-embed

1 024 nombres par vecteur · lots de 50

14 903

vecteurs pour l'ensemble des 7 586 événements

Les métadonnées relient chaque passage à son événement d'origine.

Mistral reçoit la question et quatre passages

QUESTION

mistral-embed

Le même espace
vectoriel que le corpus.

RECHERCHE

FAISS · top 4

→ Passages + titres,
lieux, dates et URL.

RÉDACTION

Ministral 8B

→ Réponse française
à partir du contexte.

« Réponds uniquement à partir du contexte fourni.
Si le contexte ne permet pas de répondre, dis que tu ne sais pas. »

Le prompt encadre la réponse ; il ne garantit pas un refus fiable dans tous les cas.

La préparation de l’index précède les questions

PRÉPARATION DU CORPUS



À CHAQUE QUESTION



[scripts/](#) lancer les étapes [src/openagenda_rag/](#) logique métier [tests/](#) vérifier

Le service réutilise le retriever et le client de chat après la première question.

L'API rend le POC accessible aux équipes

GET **/health**
État déclaré et configuration.

POST **/ask**
Question → réponse et sources.

POST **/rebuild**
Recréer l'index depuis le Parquet.

GET **/docs**
Documentation Swagger interactive.

```
{  
  "question": "Parle-moi de Concert Fishers a Paris"  
}
```

Docker · Python 3.12

Seed livré + volume persistant

Clé Mistral injectée via l'environnement

La recherche est locale ; les embeddings de question et la génération utilisent Mistral en ligne.

La démonstration montre un résultat et une limite

CAS NOMINAL

Concert Fishers à Paris

Comparer la réponse aux dates,
au lieu et au lien source.

CAS LIMITE

Expositions photo à Lyon

Observer le refus
dans un corpus limité à Paris.

Le refus est observé sur ce cas ; il dépend du prompt et du modèle.

Les tests du code et la qualité des réponses se complètent

76/76

tests réussis le 1er octobre 2026

```
python -m pytest -q  
76 passed in 2.99s
```

Code

Collecte, normalisation, chunks, persistance, API, erreurs.

Comportement

4 questions annotées ; règles sur les titres et les refus.

Qualité

RAGAS complète les règles locales avec un modèle juge.

Les tests sont locaux et automatisés ; aucune pipeline CI/CD n'est livrée.

Les scores RAGAS orientent les améliorations

0,900

Fidélité

Réponse soutenue
par le contexte.

0,846

Pertinence

Réponse adaptée
à la question.

1,000

Précision du contexte

Passages pertinents
bien classés.

0,683

Correction

Accord avec
la référence humaine.

Question + passages transmis + réponse + référence annotée → quatre métriques.

3 cas • résultats enregistrés le 23 juillet 2026 • un signal initial, pas un benchmark général.

Les limites définissent le travail avant production

01 Fraîcheur et couverture

Paris uniquement, collecte figée ; filtres métier à ajouter.

02 Pertinence et refus

Top-k sans seuil ; réponse et sources à contrôler.

03 Exploitation et qualité mesurée

API Mistral distante, quotas ; trois cas RAGAS.

Démo directe rétablie avec un autre modèle Mistral ; scores historiques à réévaluer.

Un pilote mesuré est la prochaine étape

La chaîne est livrée.

La qualité reste à mesurer à plus grande échelle.

1. Actualiser le corpus et ajouter les filtres métier.
2. Élargir le jeu annoté et calibrer la recherche.
3. Mesurer un pilote avant industrialisation.

Rapport technique · dépôt GitHub · scripts · tests · résultats documentés