

# Assistant intelligent de recommandation d'événements culturels

## Rapport technique du POC RAG pour Puls-Events

| CORPUS           | INDEX         | ZONE  |
|------------------|---------------|-------|
| 7 586 événements | 14 903 chunks | Paris |

**Technologies :** Python 3.12, LangChain, Mistral, FAISS, FastAPI, Docker, RAGAS

**Corpus :** Paris, du 2025-07-10 au 2026-07-10, source OpenAgenda/Opendatasoft

**Date du rapport :** 01/10/2026

*Ce document complète le modèle de rapport fourni et décrit uniquement les composants et résultats vérifiés dans le dépôt.*

# État vérifié pour la soutenance du 1er octobre 2026

Les données et les scores présentés dans ce rapport proviennent du POC de juillet. Le corpus est figé et doit être actualisé pour recommander des sorties actuelles. Les métriques RAGAS du 23 juillet portent sur trois cas avec mistral-small-latest ; elles ne mesurent pas le modèle alternatif utilisé pour la démonstration actuelle.

- Tests locaux : 76 réussis, sans appels externes réels.
- Démo : ministral-8b-2512 remplace mistral-small-latest, qui renvoyait HTTP 429. mistral-embed reste identique ; aucun réindexage n'a été nécessaire.
- Les deux scénarios API réels (Concert Fishers et demande à Lyon) ont réussi. Le modèle, l'horodatage et la durée sont conservés dans outputs/demo/demo\_api\_2026-10-01.json.
- Erreurs fournisseur : réponses HTTP contrôlées 503/502, sans détails internes ; le script de démo s'arrête au premier échec.
- Le prompt reçoit la date du jour et un statut temporel calculé. Cela ne filtre pas la recherche et ne garantit pas l'absence de conseils hors contexte.
- Présentation : 12 slides, conducteur de 15 minutes, explications, glossaire et questions du jury. Les pages locales séparent le direct et les réponses enregistrées.

# 1. Objectifs du projet

Puls-Events souhaite tester un assistant culturel capable de répondre à des demandes naturelles en s'appuyant sur des événements réels. Le POC démontre la faisabilité technique, la traçabilité des recommandations et l'exposition du service aux équipes produit et marketing.

- Besoin : recommandations pertinentes, formulées naturellement et vérifiables.
- Réponse : recherche sémantique dans FAISS, puis génération augmentée par Mistral.
- Périmètre livré : Paris, du 10 juillet 2025 au 10 juillet 2026.
- Volume : 7586 événements normalisés et 14903 chunks.

## 2. Architecture du système



### Séparation des responsabilités

Les scripts publics orchestrent des modules dédiés à l'ingestion, l'indexation, la génération RAG, l'API et l'évaluation. Le service OpenAgendaRAGService conserve le retriever et le modèle en mémoire.

- Entrée : API Opendatasoft v2.1, dataset evenements-publics-openagenda.
- Stockage intermédiaire : JSON brut, Parquet normalisé et manifestes.
- Recherche : embeddings mistral-embed et index local FAISS persistant.
- Génération : mistral-small-latest orchestré par LangChain.
- Livraison : API FastAPI, documentation Swagger et conteneur Docker.

# 3. Préparation et vectorisation des données

## Collecte et filtres

- Ville : Paris.
- Fenêtre : 2025-07-10 à 2026-07-10.
- Pagination complète, déduplication par identifiant et gestion des champs absents.
- Schéma stable incluant texte, ville, lieu, coordonnées, dates, URL et catégories.

## Chunking et embeddings

Chaque `text_for_embedding` est découpé en chunks de 1000 caractères avec 200 caractères de chevauchement. Les vecteurs sont produits par `mistral-embed` par lots de 50.

```
python scripts/fetch_events.py --city Paris --start-date 2025-07-10 --end-date 2026-07-10
python scripts/build_index.py --rebuild
```

## 4. Choix du modèle NLP

- Embeddings : mistral-embed, adapté à la similarité sémantique et intégré à LangChain.
- Génération : mistral-small-latest, compromis coût, latence et qualité pour le POC.
- Prompt : réponse en français, fondée uniquement sur le contexte, avec refus explicite si l'information manque.
- Température basse et graine fixe pour stabiliser les démonstrations.

### Limites

La génération et l'évaluation dépendent de l'API Mistral. Le compte gratuit impose une exécution RAGAS séquentielle avec reprise automatique après une erreur temporaire. Les sorties restent non déterministes au mot près.

## 5. Construction de la base vectorielle

FAISS est retenu pour sa rapidité, sa portabilité et sa persistance locale. L'index livré est versionné dans `seed-data/index/faiss/` et copié vers `data/index/faiss/` pour les exécutions locales. Il est accompagné d'un manifeste et d'un parquet d'inspection.

- 7586 événements indexés.
- 14903 documents vectoriels.
- Métadonnées : identifiants, titre, ville, lieu, dates, fuseau, URL, catégories et date source.
- Recherche top-k par similarité ; rechargement local testé après sauvegarde.

## 6. API et endpoints exposés

- GET /health : état du service et paramètres principaux.
- POST /ask : question non vide, réponse augmentée et sources.
- POST /rebuild : reconstruction complète puis réinitialisation du runtime.
- GET /docs : documentation Swagger générée par FastAPI.

```
curl -X POST http://localhost:8000/ask \  
-H "Content-Type: application/json" \  
-d '{"question": "Parle-moi de Concert Fishers a Paris"}'
```

Les questions vides et les erreurs de configuration produisent des réponses HTTP explicites. La clé Mistral n'est jamais retournée. /rebuild peut être protégé par l'en-tête X-Admin-Token.

## 7. Évaluation du système

Le jeu versionné contient 3 cas annotés. Chaque exemple conserve la question, les contextes exactement transmis au LLM, la réponse, une référence humaine, quatre scores et leur interprétation.

| Métrique                 | Score moyen | Interprétation |
|--------------------------|-------------|----------------|
| Fidélité au contexte     | 0.900       | fort           |
| Pertinence de la réponse | 0.846       | fort           |
| Précision du contexte    | 1.000       | fort           |
| Correction de la réponse | 0.683       | acceptable     |

Seuils d'interprétation : fort  $\geq 0,80$  ; acceptable  $\geq 0,60$  ; à améliorer  $< 0,60$ . Trois exemples démontrent la méthode mais ne constituent pas un benchmark statistique.

# Exemple RAGAS 1 — Concert Fishers

Question : Parle-moi de Concert Fishers a Paris

Contexte principal : [Source 1] Titre: Concert Fishers Ville: Paris Lieu: Le Gymnase Montparnasse  
Debut: 2026-06-21T19:30:00+02:00 Fin: 2026-06-21T23:30:00+02:00 Categories: non renseignees URL:  
<https://openagenda.com/fetedelamusique2026/events/concert-fishers> Contenu: Concert Fishers  
Reprises pop, rock, funk Reprises pop, rock, funk 200 Le Gymnase Montparnasse Paris Fête de la  
musique 2026

Réponse générée : Concert Fishers à Paris :

Un concert de reprises pop, rock et funk, dans le cadre de la **Fête de la musique 2026**.

**Date** : 21 juin 2026 à 19h30

**Lieu** : Le Gymnase Montparnasse, Paris

Plus d'infos : <https://openagenda.com/fetedelamusique2026/events/concert-fishers>

Si tu aimes les ambiances festives et les reprises énergiques, cet événement est fait pour toi !

| faithfulness        | answer relevancy | context precision | answer correctness  |
|---------------------|------------------|-------------------|---------------------|
| 0.750<br>acceptable | 0.805<br>fort    | 1.000<br>fort     | 0.738<br>acceptable |

Interprétation : score global 0.823, niveau « fort ». Les écarts orientent les améliorations du prompt et des références.

# Exemple RAGAS 2 — Salon de la Photo

Question : Parle-moi de SALON DE LA PHOTO a Paris

Contexte principal : [Source 1] Titre: SALON DE LA PHOTO Ville: Paris Lieu: Grande Halle de la Villette Debut: 2025-10-09T10:00:00+02:00 Fin: 2025-10-12T19:00:00+02:00 Categories: photographie amateurs professionnels matériels exposition salon URL: <https://openagenda.com/totaleimpro20/events/salon-de-la-photo> Contenu: SALON DE LA PHOTO Rendez-vous incontournable des amateurs et des professionnels de la photographie Du 9 au 12 octobre 2025, de 10h à 19h, les portes d'un lieu hors du temps s'ouvrent aux photographes, vidéastes et créateurs de tous horizons — passionnés curieux, débutants rêveurs ou professionnels aguerris. Quatre jours pour vivre une parenthèse i...

Réponse générée : SALON DE LA PHOTO à Paris  
Du 9 au 12 octobre 2025 (10h-19h)  
Grande Halle de la Villette  
Plus d'infos : <https://openagenda.com/totaleimpro20/events/salon-de-la-photo>

Pourquoi y aller ?  
Événement incontournable pour les amateurs et professionnels de photographie, avec expositions, matériel, ateliers et rencontres. Idéal pour s'inspirer, se former ou s'équiper.

Entrée payante (places gratuites possibles).

| faithfulness  | answer relevancy | context precision | answer correctness  |
|---------------|------------------|-------------------|---------------------|
| 1.000<br>fort | 0.817<br>fort    | 1.000<br>fort     | 0.730<br>acceptable |

Interprétation : score global 0.887, niveau « fort ». Les écarts orientent les améliorations du prompt et des références.

# Exemple RAGAS 3 — Sortie en famille

Question : Je cherche une sortie en famille a Paris avec une visite theatricalisee

Contexte principal : [Source 1] Titre: Activité en famille : une visite théâtralisée dans le Marais Ville: Paris Lieu: Pont Marie Debut: 2025-08-27T14:30:00+02:00 Fin: 2025-09-21T16:00:00+02:00 Categories: non renseignees URL: <https://openagenda.com/univers-oui-sortir/events/activite-en-famille-une-visite-theatralisee-dans-le-marais> Contenu: Activité en famille : une visite théâtralisée dans le Marais Plongez dans une aventure touristique captivante où des comédiens vous guideront à travers le quartier mythique du Marais.

Réponse générée : Voici des suggestions de visites théâtralisées en famille à Paris :

### 1. Visite théâtralisée dans le Marais

- **Pourquoi ?** Une aventure guidée par des comédiens dans le quartier historique du Marais, idéale pour les familles.
- **Lieu :** Pont Marie, Paris
- **Dates :** Du 27 août au 21 septembre 2025
- **Horaires :** 14h30 à 16h00
- **Lien :** OpenAgenda : <https://openagenda.com/univers-oui-sortir/events/activite-en-famille-une-visite-theatralisee-dans-le-marais>

### 2. Visite théâtralisée des Passages Couverts

- **Pourquoi ?** Une expérience immersive et ludique où vous enquêtez dans les passages couverts de Paris (Passage Jouffroy, etc.).
- **Lieu :** Passages couverts, Paris
- **Dates :** Du 2 août au 31 octobre 2025
- **Horaires :** 14h30 à 16h00 (attention, l'heure de début semble incorrecte dans la source, vérifiez sur le lien)
- **Lien :** OpenAgenda : <https://openagenda.com/univers-oui-sortir/events/une-experience-insolite-en-famille-une-visite-theatralisee-des-passages-couverts>

### 3. Visites Spectacles (concept immersif)

- **Pourquoi ?** Des comédiens transforment Paris en décor de théâtre avec des scénarios variés (enquêtes, contes, pièces en plein air).
- **Lieu :** Plusieurs quartiers de Paris (parcours variables)
- **Dates :** Du 28 mars au 27 décembre 2026
- **Horaires :** 14h30 à 17h00 (selon le parcours)
- **Lien :** OpenAgenda : <https://openagenda.com/univers-oui-sortir/events/visites-spectacles-decouvrez-paris-comme-vous-ne-lavez-jamais-vu>

Conseil : Réservez à l'avance pour les visites à places limitées (ex. : Chaillot - Théâtre national de la Danse).

| faithfulness  | answer relevancy | context precision | answer correctness   |
|---------------|------------------|-------------------|----------------------|
| 0.950<br>fort | 0.916<br>fort    | 1.000<br>fort     | 0.581<br>a ameliorer |

Interprétation : score global 0.862, niveau « fort ». Les écarts orientent les améliorations du prompt et des références.

## 8. Recommandations et perspectives

- Élargir le jeu annoté à plusieurs villes, catégories, saisons et cas négatifs.
- Ajouter un seuil de similarité afin de rejeter plus tôt les questions hors corpus.
- Renforcer le prompt pour mieux aligner la réponse avec la référence attendue.
- Automatiser la collecte, la reconstruction et l'évaluation dans une CI.
- Ajouter authentification, supervision, limites de débit et tests de charge avant production.

Le POC fournit une première preuve de faisabilité : l'évaluation historique obtient une précision de contexte de 1.000 et la démonstration API complète s'exécute en moins de cinq minutes.

## 9. Organisation du dépôt GitHub

|                     |                                                     |
|---------------------|-----------------------------------------------------|
| src/openagenda_rag/ | logique ingestion, indexation, RAG, API, évaluation |
| scripts/            | commandes publiques et démonstration                |
| tests/              | tests réseau-off et fixtures annotées               |
| seed-data/          | corpus et index FAISS reproductibles                |
| Dockerfile          | image de l'API                                      |
| docker-compose.yml  | exécution locale avec volume persistant             |

environment.yml est la source Conda et requirements.txt sert aux installations pip et Docker. .env et les secrets sont ignorés par Git.

# 10. Annexes

## Commandes de reproduction

```
conda env create -f environment.yml
conda activate openagenda-rag
python scripts/check_env.py
python scripts/evaluate_ragas.py
docker compose up --build
bash scripts/demo_api_5min.sh
```

## Traçabilité de l'évaluation

- RAGAS : version 0.4.3.
- Jeu annoté SHA-256 : baa353ade6616233685ddc08cf0d28f24b56754f69631ced12c7b635da65b502.
- Manifeste FAISS SHA-256 : 0d8c452633033b6dfd89afaa7069369dfbe65c501821ce3d8fc8998021922fb9.
- Commit de l'évaluation : 07365f3.
- Modèle juge : mistral-small-latest.
- Modèle d'embedding : mistral-embed.
- Évaluation générée le 2026-07-23T14:36:49Z.

## Supports de soutenance versionnés

- outputs/openagenda-rag-soutenance.pptx : présentation de 12 slides.
- docs/soutenance/script\_soutenance\_15min.md : conducteur oral de 15 minutes.
- docs/soutenance/questions\_reponses.md : questions et réponses techniques et métier.
- outputs/demo/demo\_api\_2026-10-01.json : preuve de démonstration du jour avec modèle et horodatage.
- outputs/AVANT-14H.md : préparation, vérifications et fichiers à ouvrir.